هدف این تمرین آشنایی با فرایند جمع‌آوری داده از وب و آماده‌سازی آن برای تحلیل‌های داده‌محور است. در مثال ارائه‌شده در کلاس، یک سناریوی فروشگاه خرده‌فروشی در نظر گرفته شد. برای شبیه‌سازی داده‌های این فروشگاه، اطلاعات مربوط به فروشگاه‌ها و محصولات از وب‌سایت اُکالا استخراج گردید و بر اساس این داده‌ها مجموعه‌ای از تراکنش‌های فرضی ساخته شد.

در این تمرین لازم است هر دانشجو همین روند را برای یک وب‌سایت دیگر انجام دهد. پیشنهاد می‌شود از وب‌سایت اسنپ‌فود استفاده کنید، اما انتخاب وب‌سایت‌های مشابه دیگر نیز بلامانع است؛ تنها شرط این است که منبع داده متفاوت از نمونه استفاده‌شده در کلاس باشد.

مرحله اول: استخراج داده‌ها

در ابتدا باید اطلاعات موردنیاز را از وب‌سایت انتخابی استخراج کنید. داده‌هایی که لازم است جمع‌آوری شوند شامل موارد زیر هستند:

- نام فروشگاه‌ها (در صورتی که پلتفرم شامل چند فروشگاه باشد مانند اسنپ‌فود در غیر این صورت به صورت تصادفی ایجاد کنید)

-موقعیت یا آدرس فروشگاه‌ها

-فهرست محصولات

-ویژگی‌ها و مشخصات قابل مشاهده هر محصول

-قیمت محصولات

مرحله دوم: یکسان‌سازی محصولات

در بسیاری از پلتفرم‌ها مانند اسنپ‌فود، هر فروشگاه مجموعه متفاوتی از محصولات را ارائه می‌دهد. برای ساده‌سازی تمرین، فرض کنید تمامی محصولاتی که استخراج کرده‌اید در همه فروشگاه‌ها قابل ارائه هستند.

مرحله سوم: ساخت داده‌های تراکنش

پس از جمع‌آوری و یکسان‌سازی داده‌ها، باید دو مجموعه داده برای شبیه‌سازی تراکنش‌ها ایجاد کنید:

1. Ticket: شامل اطلاعات سطح تراکنش (مانند شناسه تراکنش، شناسه فروشگاه، زمان تراکنش و موارد مشابه)

2. TicketItem: شامل اقلام داخل هر تراکنش (مانند شناسه تراکنش، شناسه محصول، تعداد و قیمت محصول در تراکنش)

در جلسات بعدی از داده‌های این دو DataFrame استفاده خواهد شد تا آن‌ها را به ساختار مناسب برای تحلیل و مدل‌سازی OLAP تبدیل کنیم.